

Profesor: Nicolás MORENO

Grupo: 01

18 de agosto de 2022.

Los métodos de Cadenas de Markov Monte Carlo (MCMC) son utilizados para simular valores de cierta densidad objetivo f cuya forma cerrada no sea conocida o simplemente no la podemos simular fácilmente. La estrategia de muestreo detrás del MCMC, es construir una cadena de Markov irreducible y aperiódica cuya distribución estacionaria sea la función objetivo f . Esto es, para un t suficientemente grande, una realización X_t de esta cadena tendrá una distribución cercana a f y además

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n h(X_i) = \mathbf{E}_f(h(X))$$

lo cual obviamente nos permite aproximar integrales (por eso Monte Carlo en el nombre del método).

Problema 1. Para ejemplificar esto, defina la siguiente cadena de Markov $x_t = \beta x_{t-1} + \varepsilon_t$, donde ε_t es una secuencia iid con distribución normal(0,1). Realice simulaciones de x_t con $\beta = 0,9$ para obtener que la distribución estacionaria es normal(0, $1/(1 - \beta^2)$). Justifique muy bien la conclusión anterior, utilizando métodos gráficos y test.

Existen varias estrategias para construir la cadena de Markov cuya distribución estacionaria coincida con f , una de ellas es el algoritmo de Metropolis-Hasting. Dada una función objetivo f , se le asocia una densidad $q(x|y)$ la cual, en la práctica, sea más fácil de simular. El soporte de la función $q(\cdot|y)$ debe contener el soporte de f .

Algoritmo 1: Metropolis-Hasting

1. Simule $Y_t \sim q(y|x_t)$

2. Tome

$$X_{t+1} = \begin{cases} Y_t & \text{con probabilidad } \rho(x_t, Y_t) \\ x_t & \text{con probabilidad } 1 - \rho(x_t, Y_t) \end{cases}$$

$$\text{donde } \rho(x, y) = \min \left\{ \frac{f(y)q(x|y)}{f(x)q(y|x)}, 1 \right\}$$

Problema 2. Utilizando el algoritmo anterior. Simule variables aleatorias de una Beta(2, 6). Realice comprobaciones gráficas y aplique tests apropiados.

El esquema bayesiano se puede explicar de la siguiente manera. Suponga que observamos unos datos Y que provienen de una distribución que depende de un parámetro θ , digamos $p(y|\theta)$, el parámetro θ tiene a su vez una distribución que se llama a priori, denotada por $p(\theta)$, entonces la distribución a posteriori (la distribución del parámetro dado los datos) aparece como una aplicación del teorema de Bayes.

$$p(\theta|y) = \frac{p(\theta)p(y|\theta)}{p(y)}$$

Es en este contexto donde el algoritmo Metropolis-Hasting es comúnmente utilizado para samplear desde la distribución $p(\theta|y)$. Naturalmente, la función de densidad a priori se puede utilizar como la función candidata $q(\cdot|y)$ de nuestro algoritmo.

Problema 3.

- Simule (sin usar MCMC) una muestra aleatoria de tamaño 100 de la siguiente mezcla de distribuciones.

$$(1 - \alpha) \text{ normal}(7, 0,5^2) + \alpha \text{ normal}(10, 0,5^2)$$

donde $\alpha = 0,7$.

- Utilizando la data simulada en el punto anterior y suponiendo que α tiene una distribución a priori Beta(1, 1) y Beta(2, 10) simule una muestra desde la distribución a posteriori utilizando el algoritmo Metropolis-Hasting y estime $\mathbf{E}(\theta|y)$ para ambas a prioris.

Entregables: Un breve informe que fundamente la respuestas a la preguntas planteadas y un archivo de texto con los algoritmos (R o MATLAB)

Fecha de entrega: Jueves 25 de agosto antes de las 18H00.